

PAMPAR-o1 v9: Arquitectura Territorial Inspirada en el Cerebro

Un Modelo de Lenguaje con Enrutamiento Interpretatable


Lucas Ricardo Mella Chillemi · Investigador Independiente · Enero 2026

💡 Resumen

PampaR es una arquitectura de modelo de lenguaje inspirada en la organización funcional del cerebro humano. A diferencia de los transformers estándar que tratan todos los cálculos de manera uniforme, PampaR introduce **Procesamiento Territorial** donde módulos neuronales especializados se organizan en territorios funcionales coordinados por un **Tálamo** central que enruta tokens usando un enfoque híbrido: 70% reglas explícitas (LLAVES) y 30% atención aprendida.

Resultado Clave: ~45 de perplejidad en WikiText-103 con solo 14M parámetros, superando a LSTM (24M, PPL 69.1) y acercándose a Transformer-XL Small (24M, PPL 54.5) con 42% menos parámetros.

🔗 Vista General de la Arquitectura



🌐 Territorios

PampaR organiza el cómputo en 4 territorios funcionales, cada uno conteniendo módulos especializados:

Territorio	Módulos	Función	Analogía Cerebral
Expresivo	Lenguaje, Creatividad	Generación de texto fluido, ideas nuevas	Área de Broca, Hemisferio derecho
Contextual	Contexto	Memoria de trabajo, coherencia	Hipocampo, Corteza prefrontal
Formal	Lógica	Razonamiento deductivo, reglas	Corteza prefrontal
Estructural	Patrones, Matemáticas	Secuencias, números, estructura	Lóbulo parietal

🔑 LLAVES: Enrutamiento Interpretable

Las LLAVES son reglas de enrutamiento explícitas e interpretables basadas en patrones de tokens:

Módulo	Patrones de Activación
Lenguaje	"el", "la", "de", "que", artículos, preposiciones
Matemáticas	dígitos 0-9, "+", "-", "=", "%", operadores
Lógica	"si", "entonces", "porque", "por lo tanto"
Patrones	repeticiones, secuencias, estructuras regulares
Contexto	pronombres, referencias, marcadores temporales
Creatividad	adjetivos, metáforas, combinaciones novedosas

La fórmula de enrutamiento combina reglas con aprendizaje:

$$\text{pesos_enrutamiento} = \lambda \times \text{activación_LLAVES} + (1 - \lambda) \times \text{atención_aprendida} \text{ donde } \lambda = 0.7$$

⇔ Fronteras Bidireccionales

Los territorios se comunican vía 6 conexiones de frontera bidireccionales con compuertas aprendidas:

Conexión	Peso	Función
Expresivo ↔ Contextual	0.8 (Alto)	La narrativa necesita contexto
Expresivo ↔ Formal	0.5 (Medio)	Argumentación estructurada
Expresivo ↔ Estructural	0.4 (Bajo)	Estructura creativa
Contextual ↔ Formal	0.6 (Medio-alto)	Contexto lógico
Contextual ↔ Estructural	0.5 (Medio)	Patrones en contexto
Formal ↔ Estructural	0.7 (Alto)	Lógica matemática

⚙️ Configuración del Modelo

Parámetro	Valor	Entrenamiento	Valor
Parámetros Totales	14M	Dataset	WikiText-103
Dimensión Oculta	256	Hardware	GTX 1650 (4GB)
Cabezas de Atención	8	Optimizador	AdamW
Bloques Territoriales	6	Learning Rate	3e-4
Longitud de Contexto	512 tokens	Precisión	FP16 mixta
Vocabulario	32K (BPE)	Tiempo de Entrenamiento	~8 horas

📊 Comparación de Resultados

Modelo	Parámetros	PPL ↓	Año
LSTM (Merity et al.)	24M	69.1	2018
Transformer-XL Small	24M	54.5	2019
PAMPAr-o1 v9	14M	~45	2026
GPT-2 Small	125M	35.1	2019

📋 Ventajas Principales

- **Interpretabilidad:** Las LLAVES proporcionan fundamento explícito de enrutamiento
- **Eficiencia de Parámetros:** PPL competitivo con 42% menos parámetros
- **Modularidad:** Fácil agregar o modificar territorios especializados
- **Plausibilidad Biológica:** Refleja la organización funcional del cerebro

📌 Limitaciones y Trabajo Futuro

- Escala: Aún no probado a escala de 1B+ parámetros
- Tareas: Evaluado principalmente en modelado de lenguaje; necesita evaluación downstream
- Diseño de LLAVES: Actualmente manual; podría beneficiarse de aprendizaje automático de reglas

🔗 Reproducibilidad

GitHub: github.com/lucasmella-stack/PAMPAr-o1

HuggingFace: huggingface.co/lucasmella-stack/PAMPAr-o1

Licencia: AGPL-3.0-or-later · **Copyright:** © 2024-2026 Lucas Ricardo Mella Chillemi

Documento generado Enero 2026 · ✉ lucas.mella@outlook.com